

Datenbankmanagement

Prof. Dr. Gregor Hülsken

Theorie 5: Referenzen, Lookup etc. in der Praxis



Lernziele

- Einsatz von Lookup in der Praxis und die verschiedenen Verfahren dazu
- Weitere Speicherverfahren



1.	Einführung	und Überblick	

- 2. Modellierung
- 3. Normalisierung
- 4. Relationale Algebra

5. Lookup etc. in der Praxis, NoSQL

- 6. SQL Data Definition Language
- 7. SQL Data Manipulation Language
- 8. SQL Trigger
- 9. SQL Funktionen / Prozeduren
- 10. SQL Datenschutz
- 11. Transaktionen

Inhalte

✓ OTLT (On True Lookup Table)

Relationen

ENUM / Check Constrains

EAV (Entity Attribute Value)

Verteilte DB-Systeme, NoSQL



Beispiel:

Datensatz Herzschrittmacher-Implantation

09/1 (Spezifikation 15.0 SR 3)


BASIS		9	führendes Symptom	13-23	Präoperative Diagnostik
	Genau ein Bogen muss ausgefüllt werden			13-17	Indikationsbegründende EKG- Befunde
1-7	Basisdokumentation Institutionskennzeichen http://www.arge-lk.de		0 = keines (asymptomatisch) 1 = Präsynkope/Schwindel 2 = Synkope einmalig 3 = Synkope rezidivierend	13	Vorhofrhythmus 1 = normofrequenter Sinusrhythmus
2	Betriebsstätten-Nummer		4 = Synkopenbedingte Verletzung 5 = Herzinsuffizienz NYHA II 6 = Herzinsuffizienz NYHA III oder IV 9 = sonstiges		2 = Sinusbradykardie/SA-Blockierungen 3 = paroxysmales/ persistierendes Vorhofflimmern/flattern 4 = permanentes Vorhofflimmern 5 = Wechsel zwischen Sinusbradykardie und
3	Fachabteilung § 301-Vereinbarung § 301-Vereinbarung: http://www.dkgev.de	10	führende Indikation zur Schrittmacherimplantation	14	Vorhofflimmern (BTS) 9 = sonstige AV-Block
	Schlüssel 1		1 = AV-Block I 2 = AV-Block II Wenckebach 3 = AV-Block II Mobitz		0 = keiner
4	Identifikationsnummer des Patienten		4 = AV-Block III 5 = faszikuläre Leitungsstörung 6 = Sinusknotensyndrom (SSS) inklusive BTS (bei paroxysmalem/persistierendem Vorhofflimmern)		6 = nicht beurteilbar wegen Vorhofflimmerns 1 = AV-Block I. Grades, Überleitung <= 300 ms 2 = AV-Block I. Grades, Überleitung > 300 ms 3 = AV-Block II. Grades, Typ Wenckebach
5	Geburtsdatum		7 = Bradykardie bei permanentem Vorhofflimmern 8 = Karotis-Sinus-Syndrom (CSS)	15	4 = AV-Block II. Grades, Typ Mobitz 5 = AV-Block III. Grades



OTLT (One True Lookup Table)

- > Eine Tabelle für statische Referenzen mit Key als Identifier
- OO Design in Relationales DB Design gepresst

Name	Vorname	Geschlecht	Geschlecht_ID	Blutgruppe
Walkes	Otto	Männlich	1	1
Hagen	Nina	Weiblich	2	2



Datenbankmanagement

Referenzen, Lookup etc. in der Praxis



Vorteile:

- Aus Sicht des Programmierers einfache Handhabung,
- Schnelle Möglichkeit des Hinzufügens neuer Werte

> Nachteile:

- Foreign keys sind nicht anwendbar, Datenintegrität kann nicht gewährleistet werden
- Datentypen können nicht benutzt werden, da alles in dem Datentyp String gespeichert werden muss => domain integrity kann nicht gewährleistet werden
- Daraus folgt, dass die String Column groß sein muss => große Datenmenge
- SQL Statements werden komplexer und Typ konvertierungen bei Joins müssen vorgenommen werden
- Sollte der Enduser die Möglichkeit zum hinzufügen bekommen
- → Rechtschreibfehler in den Attributen können die Funktionalität des Programms stören



4			
	Einführung	una	Unerblick
		ai i a	

- 2. Modellierung
- 3. Normalisierung
- 4. Relationale Algebra

5. Lookup etc. in der Praxis

- 6. SQL Data Definition Language
- 7. SQL Data Manipulation Language
- 8. SQL Trigger
- 9. SQL Funktionen / Prozeduren
- 10. SQL Datenschutz
- 11. Transaktionen

Inhalte

- ✓ OTLT (On True Lookup Table)
- ✓ Relationen
- **ENUM / Check Constrains**
- EAV (Entity Attribute Value)

NoSQL



Relationen: Eine Tabelle für jeden Referenzwert

Eine Tabelle für jeden Referenzwert


> Vorteile:

- Daten- / Domainintegrität können gewährleistet werden
- Normalform kann eingehalten werden
- Foreignkeys

Nachteile:

 Bei großen Datenbanken müssen viele solcher Tabellen erstellt werden, kann aber durch passende Views vereinfacht werden





ID Bezeichnung

0 Mann

1 Frau

2 Unbekannt

R Geschlecht

R Mitarbeiter

R Blutgruppe



- 1. Einführung und Überblick
- 2. Modellierung
- 3. Normalisierung
- 4. Relationale Algebra
- 5. Lookup etc. in der Praxis
- SQL Data Definition Language
- 7. SQL Data Manipulation Language
- 8. SQL Trigger
- 9. SQL Funktionen / Prozeduren
- 10. SQL Datenschutz
- 11. Transaktionen

Inhalte

- ✓ OTLT (On True Lookup Table)
- ✓ Relationen
- ✓ ENUM / Check Constrains

EAV (Entity Attribute Value)

NoSQL



ENUM

- > Festdefinierte Metadaten
- Datentyp ENUM ('Männlich', 'Weiblich', 'Unbekannt')

Value	Index	
Männlich		1
Weiblich		2
Unbekannt		3

> Vorteile

Schnell da keine Joins etc.

Nachteile

- Änderung nur unter DDL
- Unflexibel
- Auslesen nur auf Metadatenbasis
- Wird nicht von allen DBMS, z.B. MYSQL(65,535 elements), PostgreSQL ab 8.3 unterstützt



Check Constraints

> Festdefinierte Metadaten, können aber mehr als reine Enums

z.B.

CHECK ([Geschlecht] IN ('Männlich', 'Weiblich', 'Unbekannt'))

CHECK ([Gehalt] >= 1500)

- > Vorteile
 - Schnell da keine Joins etc. Man kann auch Werte ausgrenzen, die eine gewisse Größe überschreiten
- Nachteile
 - Änderung nur unter DDL
 - Unflexibel
 - Auslesen nur auf Metadatenbasis
 - Nicht in allen DBMS, z.B. MSSQL unterstützt



- 1. Einführung und Überblick
- 2. Modellierung
- 3. Normalisierung
- 4. Relationale Algebra
- 5. Lookup etc. in der Praxis
- SQL Data Definition Language
- 7. SQL Data Manipulation Language
- 8. SQL Trigger
- 9. SQL Funktionen / Prozeduren
- 10. SQL Datenschutz
- 11. Transaktionen

Inhalte

- ✓ OTLT (On True Lookup Table)
- ✓ Relationen
- ✓ ENUM / Check Constrains
- ✓ EAV (Entity Attribute Value)

NoSQL



Entity-Attribute-Value Model (EAV)

> Tabelle mit Entity-Attribute-Value Columns, um flexibel Daten zu speichern

Beispiel

R Mitarbeiter

Mitarbeiter
1
2
3

Auto	
A1	
A2	

R Auto

REAV

Е	Α	V
1	Name	Meier
1	Einkommen	5000
1	Job	Angestellte
2	Name	Müller
2	Einkommen	1250
3	Job	Manager
3	Einkommen	50000
A1	Ps	120
A2	Farbe	Schwarz



Vorteile

- Wissen über die Struktur der Daten muss nicht vorhanden sein
- Daten können absolut flexibel gespeichert werden

Nachteile

- Zum Großteil wie bei der OTLT
- Selbst kleine Abfragen werden sehr komplex
 - z.B. Wie kriegt man alle Mitarbeiter, die mehr als 10.000€ verdienen?





- 1. Einführung und Überblick
- 2. Modellierung
- 3. Normalisierung
- 4. Relationale Algebra
- 5. Lookup etc. in der Praxis, NoSQL
- 6. SQL Data Definition Language
- 7. SQL Data Manipulation Language
- 8. SQL Trigger
- 9. SQL Funktionen / Prozeduren
- 10. SQL Datenschutz
- 11. Transaktionen

Inhalte

- ✓ OTLT (On True Lookup Table)
- ✓ Relationen
- ✓ ENUM / Check Constrains
- ✓ EAV (Entity Attribute Value)
- ✓ Verteilte DB-Systeme, NoSQL

Datenbankmanagement



Verteilte DB-Systeme



Es gibt verschiedene Ansätze zur Datenspeicherung

Schlüssel/Wert

(Key/Value)

Beispiele: Riak, Redis

Daten werden **ohne Schema** gespeichert. Keine Struktur regelt, was wie gespeichert wird. Ein Schlüssel kann auf ein Objekt oder einen Textwert oder eine Programmierfunktion zeigen.

Datenbanken können einfach implementiert und Daten einfach hinzugefügt werden. Da die Daten mit Hilfe eines Keys abgelegt und ausgelesen werden, ist allerdings das Auffinden gespeicherter Werte erschwert.



Spaltenorientiert

Beispiele: HBase

Ähnlich wie bei Key-Values werden die Daten in Spalten innerhalb eines abgelegt. Der Schlüsselbereich basiert auf einem eindeutigen Namen, einem Timestamp. Durch den Timestamp kann man alte von neuen Daten

Schlüsselbereiches einem Wert und unterscheiden.

Dokumentenorientiert

Beispiel: MongoDB, CouchDB

Daten für ein Objekt werden in Form eines Dokumentes gespeichert. Dokumente werden in Form von Collections zusammengefasst. Die Dokumente innerhalb einer Collection sind über einen eindeutigen Key auffindbar.

Graph

Beispiel: Neo4J, Polyglot

Geeignet für Daten, die leicht mit Hilfe eines Graphen repräsentiert werden können, beispielsweise Stammbäume, Airline-Routen, Straßenkarten.

Datenhaltung in verteilten Systemen




Wie kann ein verteiltes System auf einen gemeinsamen Datenbestand zugreifen?

Problemfelder

- Performance, speziell Latenz
- Verfügbarkeit
- Konsistenz

Einfachste Lösung: Zentrale Datenhaltung

- z.B. zentrale SQL-Datenbank
- Konsistenz: OK
- Verfügbarkeit: ?
- Performance: ?
 - Eingeschränkte Skalierbarkeit!



Replikation



Datenbestand liegt als Kopie (Replika) auf mehreren Systemen vor.


Änderungen werden auf die anderen Systeme repliziert.

Master/Slave-Replikation

- Ein Node ist Eigentümer der Daten (Master).
- Nur über den Master erfolgen Schreibzugriffe.
- Änderungen werden auf ein oder mehrere Slaves repliziert.
- Die Slaves können für Leseoperationen genutzt werden.

Peer-to-Peer-Replikation (Multi-Master)

- Alle Nodes sind gleichberechtigt.
- Schreibzugriffe erfolgen über alle Nodes.
- Vermeidung bzw. Management von Konflikten notwendig.



id: 1

id: 2

id: 3

id: 4

id: 4

id: 1

id: 2

id: 3 id: 4

id: 4

Verteilte Datenhaltung und NoSQL

Replikation



Wann gilt Änderung als erfolgreich abgeschlossen?

→ Abhängig vom Replikations-Modus

Asynchrone Replikation

- Änderung sofort abgeschlossen, wird später repliziert.
- Performance von Schreiboperationen: gut
- Datenbestand vorübergehend inkonsistent.
 - Verschiedenen Knoten haben unterschiedliche Version der Daten.

Synchrone Replikation

- Änderung erst abgeschlossen, wenn Replikation abgeschlossen.
- Alle Knoten haben gleichen, konsistenten Datenbestand.
- Schreib-Performance?
- Verfügbarkeit?

Sharding



Sharding

- Zusammengehörige Daten-Aggregate einem Node zugeordnet.
- Schreibzugriffe erfolgen nur über diesen Node.

- Lese- und Schreib-Operationen skalierbar
- Daten-Lokalität → bessere Latenz
- Konsistent: keine Konflikte, da Schreibzugriffe für einen Datensatz über einen definierten Node erfolgen.

Mittels Sharding können umfangreiche Datenmengen verwaltet werden, welche die Kapazitäten eines einzelnen Servers sprengen würden.

Der größte Nachteil des Shardings ist, dass ein Zugriff über andere Kriterien als das Aufteilungskriterium unverhältnismäßig aufwändig ist.



Abfragen über andere Kriterien oder JOINS müssen i.A. auf alle Server aufgeteilt werden. Das Datenmodell und die Zugriffspfade müssen so designed werden, dass derartige Zugriffe nur selten oder gar nicht vorkommen, sonst werden die Vorteile des Shardings zunichte gemacht.

Ideal für NoSQL

id: 2

id: 4

id: 1

id: 3

Caching



Clients verwalten eigene Kopie der Daten (oder Teilen davon).

Vorteile

- schneller, lokaler Zugriff
- Entlastung des Netzwerks und der Server




- Konsistenz: Wie lange sind die gecachten Daten gültig?
- Bei Schreiboperationen im Cache sind Konflikte möglich.

Beispiele

- DNS
- Browser-Cache

https://developers.google.com/web/fundamentals/performance/optimizing-content-efficiency/http-caching?hl=de

- Offline-Webanwendungen
- Microsoft BranchCache, Windows Updates



Map/Reduce



- Programmier-Modell zur Parallelisierung
 - Häufig in Software-Frameworks realisiert
 - z.B. Hadoop, MongoDB
- Bearbeitung von komplexen Aufgaben in 2 Phasen:

Map und Reduce

Map

- Gesamtaufgabe wird in einzelne Arbeitspakete aufgeteilt und auf verschiedene Nodes verteilt.
- Nodes bearbeiten jeweilige Teilaufgabe unabhängig voneinander
- Parallele Bearbeitung durch die Nodes möglich!

Reduce


Zusammenfügen der Teilergebnisse der einzelnen Nodes

Verteilte Datenhaltung und NoSQL

Map/Reduce: Beispiel











Beispiel: Map



Input:

- Jeweils ein einzelnes Dokument
- z.B. Rechnung mit verschiedenen Positionen

Produkt	Anzahl	Einzel-Preis	Preis
Äpfel	5	0,20	1,00
Birnen	10	0,30	3,00

Output:

Key/Value Paare für jede einzelne Rechnungs-Position

Äpfel: { anzahl=5, preis=1.00 }

Birnen: { anzahl=10, preis=3.00 }

Jeder Map-Aufruf ist unabhängig von allen anderen.

→ Parallelisierbar!

Beispiel: Reduce



Input:

Map-Ausgaben für einen bestimmten Key

Von vielen Map-Instanzen

Hier: Key = Produkt, z.B. Äpfel

Äpfel: [{ anzahl=5, preis=1.00 }, { anzahl=20, preis=3.50 }, ...]

Output:

Berechnung aus den Werten für einen Key

- Hier: Berechnung der Summe (→ Gesamt-Anzahl, Umsatz) für ein Produkt.
- Äpfel: { anzahl=5320, preis=1010.80 }

Optimierung:

Verschiedene Reduce-Nodes berechnen parallel die Werte für verschiedene Keys.

Map/Reduce



Steuerung der Abläufe durch ein Framework.

Verbleibende Aufgaben:

- Programmierung der map- und reduce-Funktionen
 - Werden vom Framework aufgerufen.
 - Keine Komplikationen durch Parallelisierung → einfach zu implementieren
- Registrierung der verfügbaren Nodes am Framework.


Ablauf Map/Reduce:

- 1. Aufteilung aller Dokumente und Zuweisung zu Map-Nodes.
- 2. Weiterleitung der Map-Ergebnisse an die Reduce-Nodes.
- 3. Abholen des aggregierten Gesamt-Ergebnisses von den Reduce-Nodes.

CAP-Theorem



- Eric Brewer (2000)
- Lynch+Gilbert (2002): Formaler Beweis



Aussage:

Nicht alle drei Eigenschaften sind in einem verteilten System vollständig erreichbar!

- Consistency: Konsistenz (Lese-/Schreib-Konsistenz)
- Partition Tolerance:

Ausfall von Kommunikationsverbindungen im Cluster wird toleriert.

Availability:

Nicht-ausgefallene Nodes antworten (!)

Verteilte Datenhaltung und NoSQL

CAP-Theorem




- SQL: Fokus auf Konsistenz
 - → bei Partitionierung Verlust der Verfügbarkeit
- NoSQL: Aufweichung der starken Konsistenz
 - BASE Basically Available, Soft state, Eventual consistency
 - Erlaubt vorübergehende Inkonsistenzen
- Je nach Anforderung unterschiedliche Konsistenzregeln konfigurierbar:
 z.B. Quorum-Regeln ("Schreibvorgang muss auf mehr als der Hälfte der Nodes bestätigt sein.")

CAP-Theorem und Konsistenz



- P-Theorem und Konsistenz

 Wird das eine besser, wird zugleich das andere schlechter
- Parameter:
 - Anzahl der Replikate (Knoten mit Kopien der Daten)
 - Anzahl der Knoten, die READ bestätigen müssen.
 - Anzahl der Knoten, die WRITE bestätigen müssen.
- Forderung für starke Schreib-Konsistenz: $W > \frac{N}{2}$







"Not Only SQL"

NoSQL steht für "Not only SQL" für Datenbanken, die nicht zu den traditionellen relationalen Datenbankmanagementsystemen gehören.

Ziele sind ein einfacheres Design, einfachere Skalierung, und Kontrolle über die Daten. Bei diesen Datenbanksystemen werden die traditionellen relationalen Datenbankstrukturen aufgehoben, so dass Modle implementiert werden können, die näher an den Datenanforderungen sind.

No SQL Systeme = 150 Produkte!

Gruppen:

- Document Stores f
 ür Dokumente, ohne Schema, kein Modell
- Key Values Based (Schlüssel -> Wert, ein wenig wie Tupel)
- Column based Stores Big Table (hier ist Google sehr aktiv)
- Graph wie ein White Board (Weg-Suche, Beziehungsgeflechte)



Document Stores:

- MongoDB ähnlich wie SQL,
- CouchDB MapReduce,
- Riak (auch Key Value, Jason)
- Lotus Notes (ähnelt CouchDB)
- → Sharding



Kes Value Stores

- Redis: legt auch Datentypen ab, bietet Listenfunktion
- memcache, memcachdb (facebook):
- Riak (eigentlich Document Store)
- BerkeleyDB (oft auf Unix)
- Tokyo Cabinet
- Project Voldemort

Basis der KV ist Performance, Basis für Cches



Wide Column (Column based)

- Big Table (von Google)
- Simple DB (Amazon Webservices AWS)
- Cassandra (Hadoop)
- Hbase (Hadoop)
- Sybase IQ

Infomationen per MapReduce über verschiedenen Rechner durch legen der Spalten auf verschiedenen Rechnern

NoSQL



Graphen Datenbanken

- Neo4J (enthält Wegsuchen-Allgorithmen)
- FlockDB
- InfoGrid
- Trinity (in Csharp)

DBs berücksichtigen verschieden Beziehungsformen

Infomationen per MapReduce über verschiedenen Rechner durch legen der Spalten auf verschiedenen Rechnern

Schwer horizontal skalierbar

NoSQL



Weitere

- OrientDB (kombination)
- Dateisysteme (ähnlich wie WebDAV)
- Integrationen in MySQL (Storage Engines, aber auch memory tables)
- Lucene Search

- Hadoop [hädop] (Basis für NoSQL, aus Apache)
 - Map Reduce Framework
 - Yarn Management (Management, statet Prozesse, monitoring etc)
 - HDFS (Hadoop Distributed File System)
 - Hadoop Core: Hbase, Cassandra,

NoSQL



- Kein definierter Begriff
 - ... außer anders als SQL-Datenbanken zu sein.
- Fokus auf Performance und Skalierbarkeit
 - ... auf Kosten der Konsistenz
- An Anforderung optimierte, unterschiedliche Datenmodelle Polyglot Persistence

Datenmodelle

	Key-Val	ue-Stores	z.B.	Riak
--	---------	-----------	------	------

- Dokumenten-orientiert z.B. Mongo (oder Lotus)
- Column-Family-Stores
 z.B. HBase oder Cassandra
- Graph-Datenbanken z.B. Neo4J

Map Reduce




Beispiel: Wörter zählen:

Texte aus einem Projekt werden eingelesen. Es soll ermittelt werden, welche Wörter wie oft verwendet werden.

Koordinator:

Für jedes Kapitel wird ein Prozess angestossen. -> Map Prozess sollte nah an den Daten laufen



NoSQL



- Kein definierter Begriff
 - ... außer anders als SQL-Datenbanken zu sein.
- Fokus auf Performance und Skalierbarkeit
 - ... auf Kosten der Konsistenz
- An Anforderung optimierte, unterschiedliche Datenmodelle Polyglot Persistence

Datenmodelle

Key-Value-Stores	z.B. Riak
------------------------------------	-----------

- Dokumenten-orientiert z.B. Mongo (oder Lotus)
- Column-Family-Stores
 z.B. HBase oder Cassandra
- Graph-Datenbanken z.B. Neo4J

Aggregat-Orientierung



Aggregat

- Hier: Sammlung von zusammengehörigen Objekten, die als Einheit behandelt werden.
- Begriff aus dem Domain Driven Design.
- Aggregate werden durch die Anwendung bestimmt.
- Aggregate bei NoSQL: Key/Value, Document, Column
- Denormalisiert

Vorteile

- Aggregate leicht auf Cluster verteilbar.
- Transaktionalität in Bezug auf Aggregate.
 - Atomare Manipulation von Aggregaten.

Key-Value-Stores



Datenmodell: Map (key → value)

- Der value ist f
 ür die DB ein Blob
 - Binary Large Object
 - DB kümmert sich nicht um die Struktur des Wertes
- Operationen nur anhand des keys:
 - get / put / delete (→ REST)
 - Atomar
- Sharding anhand des keys möglich.

Produkte (Auswahl)

Riak, Redis, Memcached, Berkeley DB, Amazon Dynamo DB

Key-Value-Stores



Use Cases

- Web-Sessions
 - Key = sessionID
- Benutzer-Profile
 - Key = userID

Weniger geeignet für

- Suche nach Eigenschaften der Values (Daten)
- Beziehungen zwischen Daten
- Bearbeitung mehrerer Werte auf einmal

Problem: Diese Anforderungen können sich *später* ergeben.

Beispiel: RIAK KV



- http://basho.com/products/#riak
 http://basho.com/products/riak-kv/
- Distributed Data Store
- Fokus: Verfügbarkeit, Skalierbarkeit
- Multi-Datacenter Replication
- REST-API über http
- Buckets: Namensräume für KV-Paare, z.B. für session, user
 - /buckets/session/keys/a7e508154711
 - /buckets/user/keys/

Beispiel: RIAK KV



Zu jedem gespeicherten Wert gehören Metadaten

- Content-Type (z.B. text/plain, text/json)
- Last-Modified

Riak nach Eigenaussage gut anwendbar für:

- Immutable data
- Small objects (< 1MB)
- Independent objects
- Objects with "natural" keys
 - Key muss durch Anwendung bestimmt werden.
- Data compatible with Riak Data Types
 - counters, sets, maps

Dokumenten-orientierte DB



DBMS versteht Struktur der Daten ("Dokumente")

→ Abfragen möglich

Beispiel MongoDB https://www.mongodb.org/

- Dokument-Format: BSON (Binary JSON)
 - JSON + date + byte-array
 - Jedes Dok hat eindeutig _id
- Strukturierung: Databases → Collections → Documents
- Schemalos: Jedes Dokument kann andere Struktur haben
 - Implizites Schema i.d.R. durch Applikation festgelegt.
- Auto-Sharding anhand eines Sharding Keys
 - z.B. Location

Beziehungen: Einbetten oder Referenzieren



Einbetten

```
// Document Order:
{
  orderID: 42;
  customer: {
    id: 112; name:
  "Hans"
  }
}
```

Vorteile

- Daten-Lokalität des Aggregates
 → schneller Zugriff Order → Customer
- Atomarer, isolierter Zugriff

Nachteil

Größe der Dokumente?
 Wichtig bei 1:n

Referenzieren

```
// Document Order:
{
  orderId: 42;
  customerID: 112
}
// Document Customer
{
  customerID: 112;
  name: "Hans";
  orders: [ 13, 42 ]
}
```

Vorteil

- Flexiblität bei Anfragen
 - Finde Bestellungen des Customers


Nachteil

- 2 Abfragen für "Finde Customer zur Bestellung 42"
- Bidirektionalität aufwändig

Graphen-DB / Neo4J

FOM Hochschule

- Entitäten (Knoten)
- Gerichtete Beziehungen (Kanten)
- Fokus: Abfragen entlang der Beziehungen
 - Alle Personen, die mit Freunden von "Alice" befreundet sind.
 - Alle Produkte, die von Personen gekauft wurden, die Produkt X gekauft haben.



Use Cases

- Soziale Netzwerke
- Empfehlungssysteme
- Knowledge Engineering

Beispiel

Neo4J: https://neo4j.com/

Polyglot Persistence



Beobachtung

- Anforderungen an Data Stores differieren stark.
 - Auch innerhalb einer Anwendung!
 - SQL nicht f
 ür alle Anforderungen geeignet, v.a. Skalierbarkeit.

→ Idee: Verwendung unterschiedlicher Data Stores.

Beispiel: eCommerce-Plattform

Session Data (Einkaufswagen): Key-Value-Store

Bestellungen: Document Store

Produktkatalog: Relational


Kunden-Netzwerk: Graph

Rückfall in Vor-DBMS-Zeiten???

Polyglot Persistence



Für verschiedene Anforderungen das jeweils beste DBMS nehmen:



Nach [Sadalage/Fowler 2013]

Zusammenfassung



- Map/Reduce
- Sharding
- CAP-Theorem, BASE
- NoSQL
- Key-Value Store Beispiel RIAK KV
- Document Store Beispiel MongoDB
- Graph DB Beispiel Neo4J
- Polyglot Persistence, Aggregat-Orientierung